

Síntesis cinemática parcial de un mecanismo de exoesqueleto de dedo mediante Evolución Diferencial y Algoritmo Genético

Resumen—Este trabajo utiliza dos técnicas de optimización, la Evolución Diferencial (ED) y el Algoritmo Genético (AG), ambas implementadas en Python, para obtener la síntesis dimensional parcial de un mecanismo de exoesqueleto de dedo, ajustando el movimiento hasta la falange medial (articulación interfalángica distal, IFD). El problema se formula con 16 parámetros de diseño y una función objetivo basada en la distancia de Chamfer ponderada respecto a 120 puntos de captura de movimiento (MOCAP) de un agarre de pinza fina, tomados de la base de datos pública de cinemática de la mano de Pizzolato et al. [1], a la que se añaden una penalización por retrocesos del movimiento y un término que favorece dimensiones pequeñas. Los hiperparámetros de ambos algoritmos se sintonizan de manera simétrica con la herramienta Optuna, usando la misma semilla y el mismo número de 25 ensayos por método. Bajo este planteamiento, con la misma función objetivo, los mismos límites y el mismo número de generaciones, la ED alcanza un error global de 2.17 mm frente a 2.55 mm del AG y produce un mecanismo más compacto (suma de eslabones estructurales de 347.2 mm contra 457.1 mm). El AG, no obstante, obtiene menor error en la articulación IFD (1.43 mm frente a 1.53 mm), mientras que la ED mantiene ventaja en el error global y en la falange proximal (IFP). La ED conserva una ligera superioridad en este espacio de búsqueda continuo porque su mutación diferencial ajusta el tamaño de los pasos de forma automática, lo que favorece el refinamiento de la solución. Los resultados indican que ambas técnicas son adecuadas para esta clase de síntesis dimensional y que la elección concreta debe optimizar el compromiso entre error de ajuste y compacidad del mecanismo.

Index Terms—evolución diferencial, algoritmo genético, síntesis dimensional, exoesqueleto de mano, optimización dimensional, cadena de mecanismos.

I. INTRODUCCIÓN

Los exoesqueletos de mano son dispositivos robóticos de asistencia y rehabilitación cuya función es acompañar o ayudar a recuperar el movimiento de los dedos [2]. Para que la asistencia resulte cómoda y segura, el mecanismo debe reproducir con fidelidad las trayectorias articulares naturales del dedo a lo largo de todo el rango de flexión; de lo contrario, aparecen fuerzas de reacción indeseadas en las articulaciones y el dispositivo deja de ser cómodo para el usuario [3]. Lograr ese seguimiento depende en gran medida de elegir correctamente las longitudes de los eslabones del mecanismo, un problema que se conoce como *síntesis dimensional* [4].

La síntesis dimensional para generación de trayectoria es un problema de optimización difícil: el espacio de soluciones contiene amplias regiones en las que el mecanismo simplemente no ensambla o invierte su movimiento, y la relación entre las longitudes de los eslabones y la curva que describe

el mecanismo es no lineal y presenta muchos óptimos locales. Por ello, los métodos clásicos basados en gradiente suelen quedar atrapados en soluciones subóptimas, lo que motiva el empleo de metaheurísticas poblacionales como la Evolución Diferencial (ED) y los Algoritmos Genéticos (AG), capaces de recorrer el espacio de búsqueda sin necesitar información de derivadas [4], [5].

Aunque ambas técnicas de optimización se usan ampliamente, cuál de las dos resulta más eficaz depende de la naturaleza del problema, de cómo se representan las variables y del ajuste de los hiperparámetros [6], [7]. La elección entre uno u otro rara vez es evidente y casi siempre requiere ponerlos a prueba sobre el caso concreto que se quiere resolver.

La síntesis dimensional de eslabonamientos para generación de trayectoria se ha abordado históricamente con métodos analíticos y, más recientemente, con metaheurísticas que evitan las limitaciones de los enfoques basados en gradiente sobre funciones no convexas y discontinuas [4], [5]. Los mecanismos de cuatro barras son un bloque de construcción recurrente tanto en síntesis de trayectoria como en exoesqueletos de dedo, por su simplicidad y su capacidad de aproximar curvas de acoplador complejas con pocos parámetros [3], [8]. Cuando se encadenan varias etapas de cuatro y cinco barras, el número de variables crece y el espacio de búsqueda se vuelve fuertemente multimodal, lo que hace inevitable el uso de técnicas de optimización global.

En el ámbito de los exoesqueletos de mano, diversos trabajos recientes emplean optimización basada en enjambres o evolutiva para sintonizar las dimensiones de mecanismos que reproducen la flexión natural de los dedos [2], [8]. La elección del algoritmo, sin embargo, rara vez se justifica de forma empírica sobre el mecanismo concreto. La comparación directa entre familias de algoritmos también ha sido estudiada: en problemas de dominio continuo, la ED y la optimización por enjambre de partículas tienden a comportarse de forma más natural que el AG, concebido originalmente para representaciones discretas [6], [7]. No obstante, el resultado de la comparación depende de la codificación, de los operadores y del ajuste de hiperparámetros, por lo que sigue siendo necesario caracterizar el comportamiento sobre instancias reales [9], [10].

A diferencia de esos trabajos, aquí se fija un mismo planteamiento, función objetivo y número de generaciones para ambos algoritmos sobre un mecanismo de exoesqueleto real, y se evalúa no sólo el error de ajuste sino también la

coherencia y la compacidad del mecanismo resultante, dos aspectos determinantes para su posterior fabricación.

En este trabajo se emplean ambos algoritmos en igualdad de condiciones, es decir, partiendo del mismo planteamiento, la misma función objetivo y el mismo número de generaciones, de modo que cualquier diferencia en el resultado se deba al algoritmo y no a cómo se montó el experimento. Esto con el objetivo de determinar la mejor técnica para resolver mecanismos planos.

Para que la comparación sea reproducible, se optimiza una versión *parcial* del mecanismo, que reproduce el movimiento hasta la falange medial (articulación IFD). Este caso es más pequeño que el modelo completo de tres falanges, pero conserva las dificultades esenciales del problema (el acoplamiento entre etapas, las restricciones de ensamble y la necesidad de que el movimiento no retroceda), lo que permite estudiar el efecto del algoritmo de optimización sin la complejidad añadida del modelo completo.

I-A. Contribuciones

Las contribuciones de este artículo son: (i) una formulación del problema de síntesis dimensional parcial con 16 parámetros, función objetivo basada en la distancia de Chamfer ponderada y penalizaciones de viabilidad; (ii) una comparación controlada de ED y AG bajo condiciones idénticas, que evalúa no sólo el error de ajuste sino también la coherencia y la compacidad del mecanismo resultante; y (iii) un análisis de las razones por las que la ED conserva una ligera ventaja en este problema de variables continuas.

II. MODELO CINEMÁTICO DEL EXOESQUELETO

Sobre este diseño se añade una tercera etapa de cuatro barras, con el fin de corregir problemas de seguimiento que presenta el modelo original en la articulación IFD. El presente estudio se centra en la optimización dimensional del mecanismo resultante (Fig. 1).

El dispositivo reproduce la flexión del dedo mediante una cadena de etapas acopladas accionadas por una única manivela de entrada, lo que permite gobernar todas las articulaciones con un solo grado de libertad activo. La primera etapa combina un mecanismo de cinco barras (eslabones L_1 , L_2 , L_3 , L_4 y la bancada B_1) y uno de cuatro barras (eslabones L_4 , L_5 , h_{sp} , d_{sp} y la bancada B_2 ; los soportes h_{sp} y d_{sp} forman un triángulo rectángulo cuya hipotenusa actúa como un único eslabón equivalente) que trasladan el movimiento desde la articulación metacarpofalángica (MCF) hasta la falange proximal (articulación interfalángica proximal, IFP). La segunda etapa repite el patrón de cinco barras (eslabones L_5 , L_3 , L_6 , L_7 y la bancada con longitud $F_p - 2d_{sp}$) más cuatro barras (eslabones L_7 , L_8 , c_2 y la distancia desde IFP hasta h_{sp}) para llevar el movimiento desde la IFP hasta la falange medial (articulación IFD). Las falanges proximal F_p y medial F_m forman la línea del dedo (articulaciones MCF, IFP e IFD), mientras que la cadena de eslabones L_1 – L_8 se ubica sobre el dorso. Se indican las bancadas B_1 y B_2 , y el balancín c_2 , los desplazamientos del soporte h_{sp} y d_{sp} , y el ángulo auxiliar




Figura 1. Mecanismo simplificado del exoesqueleto montado sobre un dedo simbólico: la cadena de eslabones L_1 – L_8 se sitúa sobre el dorso de la mano y las falanges F_p y F_m se alinean con las falanges proximal y medial del dedo. Las dimensiones de los eslabones representadas corresponden al mecanismo *antes de optimizar*.

$\theta_{aux_{fm}}$ que orienta la falange medial respecto al balancín c_2 . Las juntas de revoluta se dibujan como círculos blancos y los apoyos fijos con achurado. El modelo se detiene en la falange medial; el tercer mecanismo de cuatro barras y la falange distal no forman parte de esta versión. El modelo *completo* incorpora además una tercera etapa de cuatro barras que ubica la falange distal; en este estudio se emplea el modelo simplificado, que analiza hasta la falange medial. Esta elección reduce la instancia sin perder las dificultades esenciales del problema (acoplamiento de etapas, restricciones de ensamble y monotonicidad del movimiento).

Las longitudes de las falanges se consideran fijas y se toman de las medidas de un dedo humano real: falange proximal $L_{FP} = 49$ mm, falange medial $L_{FM} = 26$ mm y falange distal $L_{FD} = 24$ mm (esta última sólo en el modelo completo). Dada una posición de manivela θ_2 , la entrada de la primera etapa se obtiene mediante una relación de engranaje r_g y un desfase θ_{off} como $\theta_1 = \theta_2/r_g + \theta_{off}$. La cinemática directa resuelve de forma secuencial los lazos de cuatro barras y propaga las posiciones de la IFP y la IFD a lo largo de todo el barrido de la manivela. Cuando una configuración no ensambla, produce valores no finitos o genera un retroceso de la falange medial (no monotonicidad del ángulo de la IFD), la pose se marca como inviable y se descarta. La Fig. 1 muestra el mecanismo simplificado del exoesqueleto montado sobre un dedo simbólico: la cadena de eslabones L_1 – L_8 se sitúa sobre el dorso del dedo, las falanges F_p y F_m se alinean con las falanges proximal y medial, y se etiquetan los parámetros de diseño. Las dimensiones de los eslabones representadas en la Fig. 1 corresponden al mecanismo *antes de optimizar* (diseño de partida); la síntesis dimensional descrita en las secciones siguientes ajusta estas longitudes hasta las soluciones reportadas.

III. FORMULACIÓN DEL PROBLEMA DE OPTIMIZACIÓN

III-A. Variables de diseño

El vector de diseño $\mathbf{p} \in \mathbb{R}^{16}$ agrupa las dos bancadas, los ocho eslabones L_1-L_8 , el balancín c_2 de la segunda etapa de cuatro barras, los desplazamientos del soporte h_{sp} y d_{sp} , el ángulo auxiliar de la falange medial θ_{aux}^{FM} , la relación de engranaje r_g y el desfase angular de entrada θ_{off} . La Tabla I resume los límites de búsqueda. Las longitudes de cada eslabón se acotan a 60 mm como máximo para favorecer un mecanismo compacto y fabricable, y el ángulo auxiliar θ_{aux}^{FM} se limita a 70° para evitar una hiperflexión anatómicamente inviable de la falange medial que provocaría interferencia mecánica con el dedo del usuario.

Tabla I
VARIABLES DE DISEÑO Y LÍMITES DE BÚSQUEDA

Parámetro	Mín.	Máx.
B_1, B_2 (mm)	15	60
L_1-L_8 (mm)	10	60
c_2 (mm)	10	55
h_{sp} (mm)	5	30
d_{sp} (mm)	5	23
θ_{aux}^{FM} (deg)	0	70
r_g (relación de engranaje)	1.0	8.0
θ_{off} (rad)	$-\pi$	π

III-B. Función objetivo

El ajuste se mide con la distancia de Chamfer [11] simétrica entre la nube de puntos de captura de movimiento M y la trayectoria simulada S . Antes de evaluar el error, la trayectoria simulada se alinea de forma rígida (rotación R y traslación $\mathbf{t}$) con los datos mediante una solución de Procrustes [12], de modo que el error refleja la *forma* de la curva y no su colocación absoluta en el plano:

$$d_C(M, S) = \frac{1}{|M|} \sum_{\mathbf{m} \in M} \min_{\mathbf{s} \in S} \|\mathbf{m} - \mathbf{s}\| + \frac{1}{|S|} \sum_{\mathbf{s} \in S} \min_{\mathbf{m} \in M} \|\mathbf{s} - \mathbf{m}\|. \quad (1)$$

donde M es el conjunto de puntos de captura de movimiento (MOCAP), S es el conjunto de puntos de la trayectoria simulada, $\mathbf{m}$ y $\mathbf{s}$ son puntos individuales de cada conjunto, y $\|\cdot\|$ denota la norma euclidiana en el plano. El primer término penaliza los puntos del MOCAP sin un punto simulado cercano y el segundo penaliza puntos simulados que se alejan de la curva objetivo; su suma es una métrica robusta frente a diferencias de muestreo entre ambas curvas.

La función objetivo combina el error de forma de las dos trayectorias (la de la IFP y la de la IFD), una penalización de monotonidad P_{mono} sobre la IFD para evitar retrocesos del movimiento, y dos términos de regularización suave que empujan hacia dimensiones y ángulo auxiliar pequeños sin degradar el ajuste. El término P_{mono} penaliza inversiones de trayectoria (ganchos o bucles) en las que el mecanismo del exoesqueleto retrocede sobre su recorrido; su inclusión garantiza que la trayectoria simulada progresa de forma monótona

sin formar lazos que provocarían atascos en el mecanismo o fuerzas no deseadas sobre el dedo:

$$f(\mathbf{p}) = w_{IFP} d_C(M_{IFP}, S_{IFP}) + w_{IFD} d_C(M_{IFD}, S_{IFD}) + w_m P_{mono}(S_{IFD}) + w_d \sum_i L_i + w_a \frac{\theta_{aux}^{FM}}{\pi}. \quad (2)$$

donde $d_C(M_{IFP}, S_{IFP})$ y $d_C(M_{IFD}, S_{IFD})$ son las distancias de Chamfer entre los puntos MOCAP y la trayectoria simulada en las articulaciones IFP e IFD respectivamente, $P_{mono}(S_{IFD})$ es la penalización por inversiones de trayectoria en la IFD, $\sum_i L_i$ es la suma de las longitudes de los eslabones estructurales, y θ_{aux}^{FM} es el ángulo auxiliar de la falange medial normalizado por π . Los pesos son $w_{IFP} = 0.40$, $w_{IFD} = 0.60$, $w_m = 5.0$ y $w_d = w_a = 5 \times 10^{-4}$. Se asigna mayor peso a la IFD porque es la articulación más alejada de la entrada y, por tanto, la más difícil de ajustar: acumula los errores de las dos etapas. Los valores de los pesos se ajustan mediante pruebas experimentales iterativas hasta obtener un equilibrio adecuado entre el error de forma, la penalización de retrocesos y la regularización. Las configuraciones inviables (sin ensamble o con retroceso) reciben una penalización fija de 1000, lo que crea amplias mesetas en el espacio de búsqueda y refuerza el carácter multimodal del problema. El planteamiento, los límites y la función objetivo son idénticos para la ED y el AG, de modo que la comparación mide el algoritmo y no el planteamiento.

La Tabla II resume las restricciones cinemáticas que se aplican durante la evaluación de cada individuo. Si alguna de estas condiciones se viola, la configuración se considera inviable y recibe la penalización fija de 1000.

Tabla II
RESTRICCIONES CINEMÁTICAS APLICADAS EN AMBOS ALGORITMOS

Restricción	Condición de penalización
No ensamble	El mecanismo no cierra en alguna pose
Valores no finitos	Se genera NaN o infinito
Retroceso de falange medial	No monotonidad de $\theta_{fm} > 0.5^\circ$
Longitudes mínimas	Algún eslabón ≤ 5 mm
Geometría del soporte	$F_p - 2 d_{sp} \leq 1$ mm
Posiciones fuera de rango	Alguna coordenada > 300 mm

IV. EVALUACIÓN DE LAS TÉCNICAS DE OPTIMIZACIÓN

Ambos algoritmos se ejecutan con la misma semilla aleatoria (42), valor convencional ampliamente adoptado en estudios previos de optimización evolutiva que garantiza la reproducibilidad de los resultados, y el mismo número máximo de generaciones (300), presupuesto validado como suficiente dado que la ED registra su última mejora cerca de la generación 257 y el AG cerca de la generación 268, de modo que ambos explotan el presupuesto completo sin estancamiento prematuro. Para evitar que el desempeño dependa de hiperparámetros elegidos a mano –en el caso de la ED: estrategia de mutación, tamaño de población, rango del factor de mutación y tasa de recombinación; en el caso del AG: tamaño de población, probabilidades de cruce y mutación,

índices de distribución SBX y polinomial, y tamaño de torneo—, una fuente habitual de sesgo al comparar metaheurísticas, los hiperparámetros de cada algoritmo se sintonizan de forma automática y simétrica con Optuna [13], empleando el muestreador por estimación de densidad arborescente (TPE, *Tree-structured Parzen Estimator*). El procedimiento es idéntico para la ED y el AG: en una primera etapa, Optuna realiza 25 ensayos por algoritmo, el mismo número para los dos, con corridas cortas que evalúan el fitness alcanzado para distintas combinaciones de hiperparámetros; en una segunda etapa, la mejor combinación encontrada se emplea en una corrida profunda de 300 generaciones, cuyos resultados son los que se reportan. La búsqueda de Optuna usa la misma semilla (42) en ambos casos, de modo que la sintonización es reproducible y equitativa. La Tabla III resume los hiperparámetros resultantes.

IV-A. Evolución Diferencial

La Evolución Diferencial es una técnica poblacional para optimización en espacios continuos, cuyas variantes y aplicaciones han sido objeto de revisiones extensas [14], [15]. En este trabajo se utiliza la implementación `differential_evolution` de SciPy con la estrategia `best1bin`. Los hiperparámetros sintonizados por Optuna son un tamaño de población relativo $\text{popsize} = 28$, un factor de mutación diferencial que varía de forma aleatoria en cada generación dentro del rango $[0.54, 0.85]$ y recombinación 0.77, con tolerancia 10^{-7} . En cada generación, los vectores de prueba se construyen a partir del mejor individuo y de la diferencia escalada entre dos individuos elegidos al azar. Esta mutación diferencial escala automáticamente sus pasos con la dispersión de la población: cuando la población está dispersa los pasos son grandes (exploración) y, conforme converge, los pasos se reducen (explotación), sin necesidad de fijar una amplitud de mutación constante.

IV-B. Algoritmo Genético

Se implementa un AG real codificado con selección por torneo (tamaño 3), cruza binaria simulada (SBX) [16] y mutación polinomial. Los hiperparámetros sintonizados por Optuna son una población de 52 individuos, probabilidad de cruza 0.63, probabilidad de mutación 0.22, índices de distribución $\eta_c = 16$ (SBX) y $\eta_m = 14$ (mutación polinomial) y elitismo de 2 individuos. La SBX y la mutación polinomial son operadores adecuados para variables continuas; sus índices de distribución, antes fijados a mano, aquí los determina Optuna junto con el resto de los hiperparámetros. Se aplica un criterio de paro temprano por estancamiento con una tolerancia de 100 generaciones sin mejora; en la corrida reportada el AG sigue mejorando hasta una fase avanzada y agota las 300 generaciones sin activar dicho paro, lo que indica que la sintonización de Optuna encuentra una configuración que mantiene diversidad genética suficiente para seguir explorando el espacio de búsqueda durante todo el presupuesto asignado.

Tabla III
CONFIGURACIÓN DE LOS ALGORITMOS (HIPERPARÁMETROS SINTONIZADOS CON OPTUNA)

Evolución Diferencial	Algoritmo Genético
estrategia: best1bin	selección: torneo (3)
popsize: 28	población: 52
mutación: (0.54, 0.85)	cruza: SBX ($\eta_c = 16$)
recombinación: 0.77	mutación: polinomial ($\eta_m = 14$)
maxiter: 300	generaciones: 300
tol: 10^{-7}	$p_{cx} = 0.63$, $p_{mut} = 0.22$
semilla: 42	élite: 2, tolerancia: 100
Sintonización: Optuna (TPE), 25 ensayos por algoritmo, semilla 42	

V. RESULTADOS

V-A. Error de ajuste

La Tabla IV reúne las métricas de ambas corridas. La ED obtiene un error global de 2.17 mm, ligeramente menor que los 2.55 mm del AG. El reparto por articulación, ilustrado en la Fig. 2, muestra que la ED ajusta mejor la falange proximal (IFP: 2.82 mm contra 3.68 mm), mientras que el AG, una vez sintonizado, reproduce con mayor fidelidad la articulación interfalángica distal (IFD: 1.43 mm contra 1.53 mm de la ED). En conjunto, las dos soluciones quedan muy próximas en error de forma, lo que confirma que ambas técnicas son capaces de propagar el movimiento de forma adecuada hasta el extremo del mecanismo.

Tabla IV
RESULTADOS DE LA OPTIMIZACIÓN (MODELO SIMPLIFICADO)

Métrica	ED	AG
Error global (mm)	2.1736	2.5543
Error IFP (mm)	2.8156	3.6813
Error IFD (mm)	1.5317	1.4273
Fitness	0.002335	0.002720
Evaluaciones (nfev)	135 970	15 052
$\sum$ eslabones estructurales (mm)	347.2	457.1




Figura 2. Error de forma (distancia de Chamfer) global, en la IFP y en la IFD para la ED y el AG. La ED domina en el error global y en la IFP, mientras que el AG ajusta ligeramente mejor la IFD.

V-B. Análisis dimensional

La Tabla V compara, eslabón por eslabón, las dimensiones del diseño CAD de referencia frente a las optimizadas por la ED y el AG. Las longitudes obtenidas por la ED son coherentes con los límites de la Tabla I y dan lugar a un mecanismo compacto, donde la suma de los once eslabones estructurales (B_1 , B_2 , L_1 – L_8 y c_2) es de 347.2 mm para la ED, 457.1 mm para el AG y aproximadamente 380.0 mm para el diseño CAD base. Es decir, la ED no sólo obtiene un error global menor, sino que además entrega el mecanismo más compacto de los tres, mientras que el AG tiende a soluciones de mayor tamaño que el propio diseño de referencia. La compacidad es deseable para la fabricación, el peso y la portabilidad del dispositivo sobre la mano del usuario, por lo que constituye un criterio de diseño tan relevante como el propio error de ajuste.

Tabla V
DIMENSIONES DE LOS ESLABONES (MM): DISEÑO CAD BASE FRENTE A LAS SOLUCIONES ÓPTIMAS DE ED Y AG

Parámetro	CAD base	ED	AG
B_1	18.00	37.33	39.19
B_2	20.00	39.62	59.87
L_1	35.00	16.00	31.84
L_2	49.00	46.56	51.84
L_3	25.00	16.61	33.01
L_4	20.00	21.60	38.83
L_5	25.00	32.15	38.15
L_6	55.00	39.85	51.26
L_7	35.00	19.16	38.22
L_8	52.00	52.07	53.01
c_2	46.01	26.30	21.84
h_{sp}	17.00	14.91	15.63
d_{sp}	18.00	7.87	5.00
$\sum$ estructurales	380.0	347.2	457.1

V-C. Biofidelidad de las trayectorias

La Fig. 3 muestra la superposición de las trayectorias simuladas por la ED contra los 120 puntos MOCAP del agarre de pinza fina: tanto la curva de la IFP como la de la IFD siguen de cerca la forma fisiológica, con errores de Chamfer de 2.82 mm y 1.53 mm respectivamente. La Fig. 4 presenta el mismo resultado para el AG, cuyas trayectorias acompañan a los datos con errores de 3.68 mm (IFP) y 1.43 mm (IFD); la curva de la IFD del AG reproduce con mayor fidelidad la flexión natural, obteniendo 0.10 mm menos de error que la ED en esa articulación. Ambas soluciones exhiben una biofidelidad satisfactoria: la ED ofrece mejor seguimiento global (2.17 mm frente a 2.55 mm del AG) y en la IFP, mientras que el AG presenta ventaja específica en la IFD.

V-D. Convergencia

La Fig. 5 presenta las curvas de convergencia. Ambos algoritmos descienden de forma sostenida y aprovechan prácticamente todo el número de generaciones disponible: la ED registra su última mejora cerca de la generación 257 y el AG cerca de la 268, de modo que ninguno se estanca de forma temprana. La ED alcanza un valor de la función objetivo de




Figura 3. Biofidelidad de la solución de la ED: trayectorias simuladas (IFP e IFD) superpuestas a los puntos MOCAP.




Figura 4. Biofidelidad de la solución del AG: las trayectorias de la IFP y la IFD siguen a los puntos MOCAP.

0.002335, mientras que el AG converge a 0.002720. Cabe notar que el AG llega a ese resultado con un número de evaluaciones de la función objetivo sensiblemente menor (Tabla IV), lo que refleja su distinto mecanismo de muestreo del espacio de búsqueda.

VI. DISCUSIÓN

El espacio de diseño de la síntesis dimensional es *continuo* y altamente multimodal, con amplias regiones inviables (sin ensamble o con retroceso de la falange medial) que generan mesetas en la función objetivo. La ventaja de la ED en este escenario proviene de la forma en que construye cada nueva solución: en lugar de aplicar un tamaño de paso fijo, suma a un individuo la diferencia entre otros dos individuos de la población. Así, la magnitud del cambio se adapta sola a lo dispersa que esté la población: cuando los individuos están repartidos por el espacio, los cambios son grandes y el algoritmo explora; cuando la población se concentra cerca de una buena solución, los cambios se reducen automáticamente




Figura 5. Curvas de convergencia de la ED y el AG. Ambos métodos descienden de forma sostenida durante casi todas las generaciones; la ED converge a un fitness de 0.002335 y el AG a 0.002720.

y el algoritmo afina el ajuste. Este ajuste automático del paso, sin necesidad de fijarlo de antemano, encaja de forma natural con variables continuas como las longitudes de los eslabones [6], [9] y explica, en buena parte, que la ED alcance un error global de 2.17 mm y, sobre todo, el mecanismo más compacto.

El AG real codificado se apoya en la cruce SBX y la mutación polinomial. Una vez que sus índices de distribución (η_c , η_m) y sus probabilidades se sintonizan con Optuna, en lugar de fijarse a mano, el AG alcanza un error global de 2.55 mm, muy cercano al de la ED, e incluso la supera en la articulación interfalángica distal (IFD). Este resultado muestra que la ED no domina sistemáticamente a los AG en problemas continuos [6], [7]: la brecha observada se reduce de manera notable cuando ambos algoritmos parten de una sintonización equitativa. La contrapartida del AG en este caso es que tiende a soluciones de mayor tamaño, lo que penaliza la compacidad del mecanismo.

Conviene señalar una limitación metodológica relativa al costo de cómputo. La ED se evalúa con una implementación vectorizada y paralela, mientras que el AG se ejecuta en Python puro; por ello, la comparación de tiempos de ejecución está sesgada y no se reporta como criterio de mérito. Se enfatiza, en cambio, la *calidad de la solución* y el número de evaluaciones de la función (nfev) como métrica de cómputo más justa. La ED alcanza un error global ligeramente menor pese a realizar más evaluaciones, mientras que el AG obtiene una solución muy próxima con un número de evaluaciones bastante menor, lo que sugiere que cada método explora el espacio de búsqueda con una eficiencia distinta.

VII. CONCLUSIÓN

Se obtiene la síntesis dimensional parcial (hasta la falange medial) de un mecanismo de exoesqueleto de dedo utilizando las técnicas de optimización Evolución Diferencial y Algoritmo Genético real codificado, bajo un planteamiento, una función objetivo y un mismo número de generaciones, y con los hiperparámetros de ambos métodos sintonizados de forma simétrica con Optuna (muestreador TPE, 25 ensayos por algoritmo). La ED obtiene un error global de 2.17 mm

frente a 2.55 mm del AG y, de manera notable, entrega el mecanismo más compacto (347.2 mm de suma de eslabones estructurales, frente a 457.1 mm del AG). Una vez sintonizado, el AG resulta competitivo e incluso ajusta mejor la articulación interfalángica distal (IFD). El análisis sugiere que, para esta clase de problemas continuos y multimodales, la mutación diferencial de la ED, que ajusta por sí sola el tamaño de sus pasos, ofrece una ligera ventaja en error global y, sobre todo, en compacidad, mientras que un AG bien sintonizado alcanza una calidad de ajuste comparable. La ED se recomienda como método de referencia cuando la compacidad del mecanismo es prioritaria, sin que ello descarte al AG como alternativa válida para esta clase de síntesis dimensional.

Como trabajo futuro se contempla: (i) extender la optimización al modelo completo de tres falanges, incorporando la falange distal y la tercera etapa de cuatro barras; (ii) realizar comparaciones multiseñilla con pruebas estadísticas para estimar la robustez de cada algoritmo; (iii) implementar ambos algoritmos en igualdad de condiciones de cómputo (mismo lenguaje y mismo nivel de vectorización), de modo que sus tiempos de ejecución puedan compararse sin sesgo; y (iv) validar físicamente el mecanismo óptimo mediante prototipado y medición de las trayectorias reales.

REFERENCIAS

- [1] S. Pizzolato, L. Tagliapietra, M. Cognolato, M. Reggiani, H. Müller, and M. Atzori, "A large calibrated database of hand movements and grasps kinematics," *Scientific Data*, vol. 4, 170151, 2017.
- [2] H. K. Yap, J. H. Lim, F. Nasrallah, and C.-H. Yeow, "Hand exoskeleton design and human-machine interaction strategies for rehabilitation: a review," *Bioengineering (MDPI)*, vol. 9, no. 11, 682, 2022.
- [3] M. A. Leal-Naranjo, C. R. Torres-San Miguel, M. Carbajal-Romero, and G. Urriolagoitia-Sosa, "Design optimization of a four-bar exoskeleton with natural finger trajectories," *Open Engineering*, vol. 13, 20220456, 2023.
- [4] J. A. Cabrera, A. Simon, and M. Prado, "Optimal synthesis of mechanisms with genetic and differential evolution algorithms," *Mechanism and Machine Theory*, vol. 73, pp. 132–145, 2014.
- [5] S. Slesongsom, S. Bureerat, and N. Pholdee, "Four-bar path generation synthesis using a teaching-learning-based optimization algorithm," *Biomimetics (MDPI)*, vol. 11, no. 3, 160, 2024.
- [6] M. Varae and M. R. Ghasemi, "Comparison of three evolutionary algorithms: GA, PSO, and DE," *Industrial Engineering & Management Systems*, vol. 11, no. 3, pp. 215–223, 2012.
- [7] J. Tvrđík, "Differential evolution versus genetic algorithms in multiobjective optimization," in *Lecture Notes in Computer Science*, Springer, 2006, pp. 1–10.
- [8] R. V. Deshmukh and H. Godse, "Optimal synthesis of the Stephenson-II linkage for a finger exoskeleton using swarm-based optimization algorithms," *Journal of Bionic Engineering*, vol. 20, pp. 1–16, 2023.
- [9] M. Pant, H. Zaheer, L. Garcia-Hernandez, and A. Abraham, "Differential evolution: a review of more than two decades of research," *Engineering Applications of Artificial Intelligence*, vol. 90, 103479, 2020.
- [10] A. K. Qin, V. L. Huang, and P. N. Suganthan, "Differential evolution algorithm with strategy adaptation for global numerical optimization," *IEEE Transactions on Evolutionary Computation*, vol. 13, no. 2, pp. 398–417, 2009.
- [11] H. G. Barrow, J. M. Tenenbaum, R. C. Bolles, and H. C. Wolf, "Parametric correspondence and chamfer matching: two new techniques for image matching," in *Proc. 5th Int. Joint Conf. Artificial Intelligence (IJCAI)*, 1977, pp. 659–663.
- [12] J. C. Gower, "Generalized Procrustes analysis," *Psychometrika*, vol. 40, no. 1, pp. 33–51, 1975.

- [13] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: a next-generation hyperparameter optimization framework," in *Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining (KDD)*, 2019, pp. 2623–2631.
- [14] S. Das, S. S. Mullick, and P. N. Suganthan, "Recent advances in differential evolution – an updated survey," *Swarm and Evolutionary Computation*, vol. 27, pp. 1–30, 2016.
- [15] A. Khellal et al., "A comprehensive review on differential evolution and its applications in image processing," *Archives of Computational Methods in Engineering*, vol. 29, pp. 4519–4565, 2022.
- [16] K. Deb and R. B. Agrawal, "Simulated binary crossover for continuous search space," *Complex Systems*, vol. 9, no. 2, pp. 115–148, 1995.